



Multilayer Perceptron

POSTECH CSE

Saemi Moon

Contents


- Review the key points
 - Multilayer Perceptron (MLP)
 - Activation function
 - Backpropagation




Contents

- Review the key points
 - Multilayer Perceptron (MLP)
 - Activation function
 - Backpropagation





- Input이 있는 layer를 0번째 layer라고 하기도 하지만, 주로 input layer라고 함
- 마지막 layer는 output layer라고 부름
- Input layer, output layer를 제외한 나머지 layer를 hidden layer라고 함





• Neural Network에서 input $x \in \mathbb{R}^D$ 가 주어졌을 때, 뉴런은 다음과 같이 정의할 수 있다.

$$f = \sigma(w^ op x + b), \; w \in \mathbb{R}^D \;\;\; b \in \mathbb{R}^D$$

 $\sigma(.)$: non linear activation function

Single layer NN

$$f=\sigma(W_1x+b_1)$$

2-layer NN

$$f=W_2\sigma(W_1x+b_1)$$


3-layer NN

$$f=W_3\sigma(W_2\sigma(W_1x+b_1)+b_2)$$


Single-Layer NN

Framework

- Input: $x=(x_1,x_2,\ldots,x_d)^ op$
- Output: y



$$y = f(z) = f(w^ op x + b)$$



Limitation of single layer NN




Figure: Let x_1 and x_2 be the inputs and y is the output from zero-hidden layer net. The network can represent any hyperplane separating input dimensions into two halves.



Why non-linear activation function?

- 데이터가 복잡해지고, feature들의 차원이 증가하면서 데이터의 분포 가 선형적으로 표현되는 경우가 매우 적음
- 선형적이지 않은 데이터는 선형적인 boundary로는 표현이 불가능 하므로 비선형 boundary가 필요함

Role of Activation function

- Activation function의 역할?
 - 만약, activation function을 사용하지 않는다면?

$$egin{aligned} \mathbf{f} &= \mathbf{W}_2(\mathbf{W}_1\mathbf{x} + \mathbf{b}) \ \mathbf{f} &= \mathbf{W}_2\mathbf{W}_1\mathbf{x} + \mathbf{W}_2\mathbf{b} \ \mathbf{f} &= \mathbf{W}'\mathbf{x} + \mathbf{b}' \end{aligned}$$

- 서로 다른 weight를 아무리 많이 곱하더라도 하나의 weigh를 곱한 것과 똑같은 표현력을 갖게 됨

Role of Activation function


- Activation function의 역할?
 - 만약, activation function으로 linear function을 사용하게 된다면?

$$f(x) = c(c(c(x))) = c^3x = ax$$

- 여러 개의 layer를 쌓더라도 하나의 layer와 같은 표현력을 갖게 됨



- Activation function의 역할?
 - Ex) 다음과 같은 X와 y가 데이터셋으로 주어졌다고 가정





- Activation function의 역할?
 - Ex) 만약 activation function(ex. ReLU)을 활용해 x와 y 사이의 관계를 아래와 같이 모델링한다면?



- Activation function의 역할?
 - Ex) 만약 activation function을 활용해 x와 y 사이의 관계를 아래와 같이 모델링 하다면?

$$W = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, C = \begin{bmatrix} 0 & 1 \\ 0 & 1 \\ 0 & 1 \end{bmatrix}, W = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\forall 2 \text{ and } 1$$



$$X = \begin{bmatrix} \overrightarrow{x}_{1} \\ \overrightarrow{x}_{2} \\ \overrightarrow{x}_{3} \\ \overrightarrow{x}_{4} \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \quad y = \begin{bmatrix} y_{1} \\ y_{2} \\ y_{3} \\ y_{4} \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}$$

$$W = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad C = \begin{bmatrix} 0 & -1 \\ 0 & -1 \\ 0 & -1 \end{bmatrix}, \quad W = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

- Activation function의 역할?
 - Ex) 만약 activation function을 활용해 x와 y 사이의 관계를 아래와 같이 모델링 하다면?

$$XW = \begin{bmatrix} 0 & 0 \\ 1 & 1 \\ 1 & 1 \\ 2 & 2 \end{bmatrix}$$

$$X = \begin{bmatrix} \overrightarrow{x}_{1} \\ \overrightarrow{x}_{2} \\ \overrightarrow{x}_{3} \\ \overrightarrow{x}_{4} \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \quad y = \begin{bmatrix} y_{1} \\ y_{2} \\ y_{3} \\ y_{4} \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}$$

$$W = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad C = \begin{bmatrix} 0 & -1 \\ 0 & -1 \\ 0 & -1 \\ 0 & -1 \end{bmatrix}, \quad W = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

- Activation function의 역할?
 - Ex) 만약 activation function을 활용해 x와 y 사이의 관계를 아래와 같이 모델링 하다면?

$$y = w^{T} \max \{0, XW + C^{3} + b$$

$$XW = \begin{bmatrix} 0 & 0 \\ 1 & 1 \\ 1 & 1 \\ 2 & 2 \end{bmatrix} \qquad XW + C = \begin{bmatrix} 0 & -1 \\ 1 & 0 \\ 1 & 0 \\ 2 & 1 \end{bmatrix}$$



$$X = \begin{bmatrix} \overrightarrow{\chi}_{1} \\ \overrightarrow{\chi}_{2} \\ \overrightarrow{\chi}_{3} \\ \overrightarrow{\chi}_{4} \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \quad y = \begin{bmatrix} y_{1} \\ y_{2} \\ y_{3} \\ y_{4} \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}$$

$$W = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad C = \begin{bmatrix} 0 & -1 \\ 0 & -1 \\ 0 & -1 \end{bmatrix}, \quad W = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

- Activation function의 역할?
 - Ex) 만약 activation function을 활용해 x와 y 사이의 관계를 아래와 같이 모델링 하다면?

$$XW+C = \begin{bmatrix} 0 & -1 \\ 1 & 0 \\ 1 & 0 \\ 2 & 1 \end{bmatrix} \quad \max\{0, XW+C\} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \\ 1 & 0 \\ 2 & 1 \end{bmatrix}$$



$$X = \begin{bmatrix} \overrightarrow{x}_{1} \\ \overrightarrow{x}_{2} \\ \overrightarrow{x}_{3} \\ \overrightarrow{x}_{4} \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \quad y = \begin{bmatrix} y_{1} \\ y_{2} \\ y_{3} \\ y_{4} \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}$$

$$W = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad C = \begin{bmatrix} 0 & -1 \\ 0 & -1 \\ 0 & -1 \end{bmatrix}, \quad W = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

- Activation function의 역할?
 - Ex) 만약 activation function을 활용해 x와 y 사이의 관계를 아래와 같이 모델링 하다면?

$$\max\{0, XW+C\} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \\ 1 & 0 \\ 2 & 1 \end{bmatrix} \qquad \omega^{T} \max\{0, XW+C\} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$



$$X = \begin{bmatrix} \vec{\chi}_1 \\ \vec{\chi}_2 \\ \vec{\chi}_3 \\ \vec{\chi}_4 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}$$

$$W = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad C = \begin{bmatrix} 0 & -1 \\ 0 & -1 \\ 0 & -1 \\ 0 & -1 \end{bmatrix}, \quad W = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

- Activation function의 역할?
 - Ex) 만약 activation function을 활용해 x와 y 사이의 관계를 아래와 같이 모델링 하다면?

$$\mathbf{W}^{\mathsf{T}} \max \left\{ 0, \mathbf{X} \mathbf{W} + \mathbf{C} \right\} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \iff \mathbf{y} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$



• One-hidden layer ($\mathbf{f} = \mathbf{W}_2 \sigma(\mathbf{W}_1 \mathbf{x} + \mathbf{b})$): Open or close boundary of convex region




Figure: The one-hidden layer can represent any bounded convex region.







Figure: The two-hidden layers can represent any combination of convex region.



Multilayer Perceptron

• Bias term





Contents

- Review the key points
 - Multilayer Perceptron (MLP)
 - Activation function
 - Backpropagation



Activation function


- 대표적인 activation function
 - Sigmoid function
 - Tanh function
 - ReLU function
 - Leaky ReLU function



Sigmoid & Tanh function


Sigmoid

$$\sigma(x) = rac{1}{1+e^{-x}} \ \sigma'(x) = \sigma(x)(1-\sigma(x))$$



Tanh Function

$$tanh(x)=rac{e^x-e^{-x}}{e^x+e^{-x}} \ tanh'(x)=1-tanh^2(x)$$



- Input이 매우 작거나 클 때*,* Gradient가 거의 0이 되는 문제가 생긴다.
- 학습이 안되는 문제가 생김


ReLU & leaky ReLU function


ReLU

$$f(x) = max(0, x)$$

Leaky ReLU

$$f(x) = max(\alpha x, x)$$





- Gradient가 없어지는 문제를 해결하고자 함
- ReLU는 음수일 때 Gradient가 없어지는 문제가 있지만, 잘 작동함
- Leaky ReLU는 음수일 때 Gradient가 없어지는 문제를 해결하여 더 성능이 좋지 만 실제로는 ReLU를 많이 사용함

Contents

- Review the key points
 - Multilayer Perceptron (MLP)
 - Activation function
 - Backpropagation



Backpropagation


• 각각의 weight와 bias에 대해서 gradient를 직접 계산해서 구해야 한다.

$$- \ rac{\partial \mathcal{L}}{\partial W_\ell}, \ rac{\partial \mathcal{L}}{\partial b_\ell}$$

- $-\frac{\partial \mathcal{L}}{\partial W_\ell} =$ 와 같은 closed form으로 gradient를 구하는 것은 매우 복잡하고, cost가 큼
- Loss가 달라지면 다시 계산을 해야함
- Complex model은 이러한 방식으로 학습이 거의 불가능 함




Backpropagation



- 다음과 같이 Neural Net이 있고, loss function은 L2-norm을 사용할 때,
 - $\frac{\partial \mathcal{L}}{\partial z}$ 는 쉽게 구할 수 있음
 - Backpropagation에서는 $\frac{\partial \mathcal{L}}{\partial z}$ 를 이용하여 $\frac{\partial \mathcal{L}}{\partial x}, \frac{\partial \mathcal{L}}{\partial y}$ 를 구함

Backpropagation



- By chain rule, $\frac{\partial \mathcal{L}}{\partial x} = \frac{\partial \mathcal{L}}{\partial z} \frac{\partial z}{\partial x}$
 - Ex) $z = f(x,y) = x^2 xy$, x = 3 , y = 1 , t = 5
 - $z=6,~\mathcal{L}=1,~rac{\partial \mathcal{L}}{\partial z}=-2*(5-6)=2$
 - $\frac{\partial z}{\partial x} = 2 * 3 1 = 5$
 - $\frac{\partial \mathcal{L}}{\partial x} = \frac{\partial \mathcal{L}}{\partial z} \frac{\partial z}{\partial x} = 2 * 5 = 10$

Connect with Neural Net

- $\ell=1,\ldots,N$ layer를 갖는 neural net
 - L번째 hidden layer를 다음과 같이 표현 $h_L = W_L \sigma(h_{L-1}) + b_L$

$$\bullet \quad \frac{\partial \mathcal{L}}{\partial W_{L}} = \frac{\partial \mathcal{L}}{\partial h_{L}} \frac{\partial h_{L}}{\partial W_{L}} \quad \Rightarrow \quad \frac{\partial \mathcal{L}}{\partial W_{L-1}} = \underbrace{\frac{\partial \mathcal{L}}{\partial h_{L}}}_{\begin{array}{c} \partial h_{L} \\ \partial h_{L} \\ \hline \partial h_{L} \\ \end{array}}_{\begin{array}{c} \partial h_{L-1} \\ \hline \partial h_{L-1} \\ \hline \partial W_{L-1} \\ \end{array}$$

- 주황색 박스부분은 이미 이전에 계산된 부분을 재사용
- 연두색 박스부분 역시 계산이 가능
- 위 과정을 반복하면 모든 weight, bias에 대해서 gradient를 계산 가능

Table of Contents

- Practice
 - Implement Backpropagation
 - Multilayer Perceptron



Implement Backpropagation

• Logistic regression을 backpropagation으로 구현하기

$$y = \sigma(Wx + b)$$

$$z = w^{T}x + b$$

$$\hat{y} = a = \sigma(z)$$

$$\mathcal{L}(a, y) = -(y \log(a) + (1 - y) \log(1 - a))$$

Implement Backpropagation(more hard)

- Two-layer neural network에 대한 backpropagation 구현하기
 - Model:


$$y = \sigma(W_2\sigma(W_1x + b_1) + b_2)$$

- Activation function은 sigmoid function사용
- Loss function:

$$\mathcal{L} = rac{1}{N} \sum_{i=1}^N (y_i - \hat{y_i})$$

Multilayer Perceptron

- MNIST 데이터를 classify하는 multilayer neural network 구현하기
 - Network design: 2 hidden layer (1st hidden layer: 128, 2nd hidden layer: 256)





Thank You:)

saemi@postech.ac.kr

